

PDF 图文混排解析

综合测试文档

Comprehensive Test Document for PDF Layout & Content Parsing

版本: v2.1.0

日期: 2026年8月

用途: 评估PDF解析器对复杂版面的识别能力

文档说明

本文档专门设计用于测试各类PDF解析工具对复杂版面的识别与还原能力。包含多栏布局、嵌套表格、嵌入图表、代码块、脚注注释、图文混排等多种排版元素。

一、测试项目概览

本文档共包含 8个核心测试模块，覆盖PDF解析中最常见的复杂场景。

序号	测试模块	解析挑战	难度
1	多栏布局与阅读顺序	识别多栏文本的正确阅读顺序，避免串栏	
2	复杂表格结构	合并单元格、嵌套表格、跨页表格的还原	
3	图表嵌入与标注	提取嵌入图片、识别图表类型、保留图注	
4	代码块与等宽字体	保留缩进、换行、语法高亮标记	
5	脚注与尾注	区分正文与注释，建立引用关系	
6	图文混排与环绕	文字与图片的相对位置关系	
7	层级标题与列表	正确识别标题层级和列表嵌套	
8	混合字体与特殊符号	中/英/数混排、数学公式、Unicode	

二、多栏布局与阅读顺序测试

本页采用三栏布局模拟报纸/学术期刊排版。解析器需要正确识别每栏边界。

【左栏】人工智能发展简史	【中栏】大语言模型的突破	【右栏】未来展望与挑战
1956年，达特茅斯会议首次提出"人工智能"概念，标志着AI作为独立学科的诞生。早期研究集中在符号推理和专家系统，如1965年的DENDRAL系统可分析化学质谱数据。	2017年，Google提出Transformer架构，"Attention Is All You Need"彻底改变了自然语言处理范式。自注意力机制使模型能够并行处理长序列。	当前AI发展面临三大核心挑战：可解释性、安全性与对齐问题。
1980年代，机器学习兴起，决策树、神经网络等算法开始展现潜力。但由于计算资源限制，AI经历了两次"寒冬"。	2020年，GPT-3以1750亿参数展示了惊人的少样本学习能力。2022年11月，ChatGPT发布，标志着生成式AI进入大众视野。	具身智能(Embodied AI)成为新热点，将感知-决策-行动闭环应用于机器人领域。同时，AI for Science在蛋白质折叠、材料发现等领域取得突破。
2012年，AlexNet在ImageNet竞赛中以巨大优势获胜，深度学习革命正式开启。	2024-2025年，多模态大模型实现了文本、图像、音频的统一理解与生成。	预计到2030年，通用人工智能(AGI)可能从理论走向实践，但伦理框架和监管体系的建设同样紧迫。

解析验证问题：

- 三栏文本是否被正确分离？左/中/右栏内容是否混在一起？
- 每栏内部的段落顺序是否正确？
- 加粗文本的格式标记是否被保留？
- 特殊符号（如"【】"、"°C"、"→"）是否正确识别？

三、复杂表格结构测试

本页包含四种不同类型的表格，全面测试解析器的表格还原能力。

3.1 基础数据表

产品型号	发布年份	参数量	上下文长度	多模态
GPT-3	2020	175B	2,048	
GPT-4	2023	未公开	8,192	
Claude 3 Opus	2024	未公开	200,000	
Gemini 1.5 Pro	2024	未公开	1,000,000	
Llama 3.1 405B	2024	405B	128,000	

表1：主流大语言模型参数对比

3.2 条件格式表（空气质量监测）

城市	PM2.5	AQI	空气质量	建议
北京	45	82	良	适宜户外活动
上海	38	68	良	适宜户外活动
广州	28	55	优	空气优良
成都	72	105	轻度污染	敏感人群减少外出
西安	95	138	轻度污染	建议佩戴口罩
石家庄	128	168	中度污染	减少户外活动

表2：城市空气质量监测数据（条件格式：绿=优/良，黄=轻度，红=中度）

四、图表嵌入与标注测试

本页包含4种Matplotlib生成的嵌入图表，测试图像提取与图注关联能力。

4.1 柱状图：季度销售对比




图1：2025年度产品A与产品B的季度销售额对比（单位：万元）

4.2 折线图：收支趋势分析




图2：2025年上半年收入与成本月度趋势，绿色区域表示利润空间

4.3 饼图：预算分配结构




图3：2026年度部门预算分配比例，研发部门占比最高（35%）

4.4 热力图：系统负载分布




图4：服务器集群在不同时间段的工作负载百分比

解析验证问题：

1. 4张图表是否都被识别为图像元素？是否有图表被遗漏？
2. 图表下方的图注是否与对应图表正确关联？
3. 解析器能否识别图表类型（柱状图/折线图/饼图/热力图）？
4. 图表中的数据标签是否被OCR正确提取？

五、代码块与等宽字体测试

解析器需要保留缩进、换行和语法高亮标记，不应将代码误识别为普通文本。

5.1 Python 数据处理示例

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split

def preprocess_data(filepath: str) -> pd.DataFrame:
    """██████████"""
    df = pd.read_csv(filepath)

    # ██████
    df['age'].fillna(df['age'].median(), inplace=True)
    df['income'] = df['income'].apply(parse_currency)

    # ████
    df['age_group'] = pd.cut(df['age'], bins=[0, 18, 35, 50, 65, 100])
    df['income_log'] = np.log1p(df['income'])

    return df.dropna(subset=['target'])

# ████
if __name__ == '__main__':
    data = preprocess_data('customer_data.csv')
    X_train, X_test, y_train, y_test = train_test_split(
        data.drop('target', axis=1),
        data['target'],
        test_size=0.2,
        random_state=42
    )
    print(f"████████: {len(X_train)}, ██████: {len(X_test)}")
```

5.2 SQL 查询示例

```
SELECT
    d.department_name,
    COUNT(e.employee_id) AS headcount,
    AVG(e.salary) AS avg_salary,
    MAX(e.hire_date) AS latest_hire
FROM departments d
LEFT JOIN employees e ON d.department_id = e.department_id
WHERE e.status = 'ACTIVE'
    AND e.salary > 50000
GROUP BY d.department_id, d.department_name
HAVING COUNT(e.employee_id) > 5
ORDER BY avg_salary DESC
```

```
LIMIT 10;
```

解析验证问题：

1. 代码块的等宽字体（Courier）是否被识别？
2. 缩进（4空格）和换行是否完整保留？
3. 注释行（以#开头）是否与代码正确区分？
4. 字符串中的特殊符号（如引号、反斜杠）是否正确提取？

六、脚注、尾注与复杂排版测试

本页测试解析器区分正文与注释的能力，以及混合字体、颜色的处理。

6.1 带注释的学术段落

Transformer架构的提出彻底改变了自然语言处理领域¹。自注意力机制允许模型在处理序列时直接关注任意位置的信息，从而解决了RNN系列模型的长距离依赖问题²。后续研究表明，仅通过增加模型参数量和训练数据规模，就能显著提升模型性能，这一现象被称为"缩放定律" (Scaling Laws)³。

1. Vaswani et al. "Attention Is All You Need." NeurIPS 2017.

2. Bahdanau et al. "Neural Machine Translation by Jointly Learning to Align and Translate." ICLR 2015.

3. Kaplan et al. "Scaling Laws for Neural Language Models." arXiv:2001.08361.

6.2 混合字体与特殊符号

现代文档常包含粗体、斜体、**红色警告文本**、**绿色成功文本**、**橙色高亮**等多种样式。数学公式如 $E = mc^2$ 、 $\sum (x - \mu)^2 / \sigma^2$ 、 $\alpha + \beta \rightarrow \gamma$ 需要正确识别。货币符号：\$100、€ 50、¥1000、£75。温度与单位：25°C、98.6°F、100km/h、45N·m。Emoji表情：👉👈。Unicode字符：→ ← ↑ ↓ × ÷ ± ≈ ≠ ≤ ≥ ∞ ∂ ∫ √。

6.3 层级标题与列表嵌套

有序列表测试：

1. 数据预处理阶段

1.1 缺失值处理（删除/填充/插值）

1.2 异常值检测（IQR方法/Z-score/孤立森林）

1.2.1 单变量异常检测

1.2.2 多变量异常检测

2. 特征工程阶段

2.1 数值特征标准化

2.2 类别特征编码

3. 模型训练与评估

无序列表测试：

支持向量机（SVM）

– 线性核函数

– RBF核函数

随机森林 (Random Forest)

梯度提升树 (XGBoost/LightGBM/CatBoost)

– 处理类别特征的优势

最终综合验证清单：

- ☐ 文档共约10页，解析结果是否保持相同页数？
- ☐ 标题层级 (H1→H2→H3) 是否正确识别？
- ☐ 4张嵌入图表是否全部提取且分辨率正常？
- ☐ 表格中的条件格式颜色是否被记录为语义信息？
- ☐ 代码块是否保持等宽字体和原始缩进？
- ☐ 脚注/尾注是否与正文正确分离？
- ☐ 中英文混排、数字、特殊符号是否完整无误？
- ☐ 列表嵌套层级 (1→1.1→1.1.1) 是否正确还原？